Fine-tuning de DistilBERT

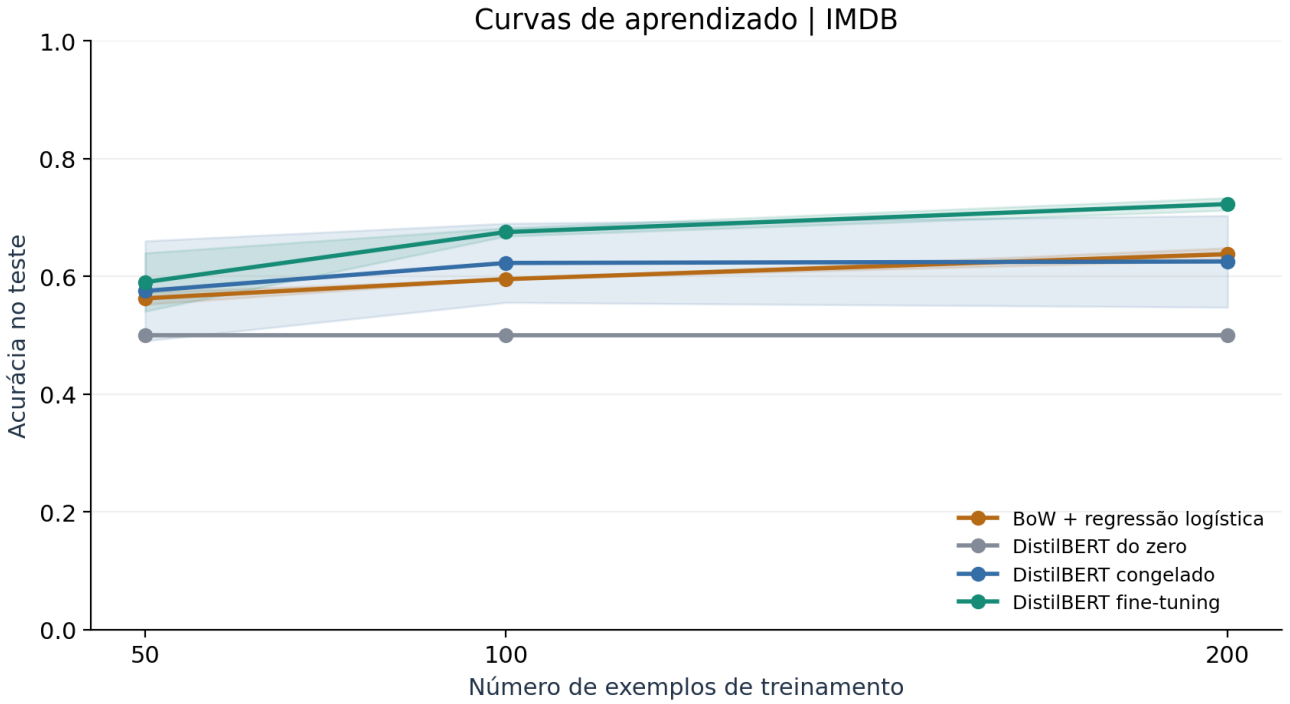
Comparação de eficiência amostral em classificação de textos

Método e escopo

Dataset: **IMDB**. Treino oficial: 25,000 textos; teste oficial: 25,000. Avaliação em 200 textos fixos. Tamanhos de treino: 50, 100, 200; sementes: 42, 43. Cada ponto resume execuções independentes.

Execução exploratória: usa uma amostra estratificada do teste oficial e um orçamento reduzido. O gráfico representa medições reais desta configuração; não estima o desempenho de um treinamento longo no teste completo.

BoW usa contagens de unigramas e bigramas e regressão logística. Os outros três métodos usam o mesmo encoder DistilBERT e uma cabeça linear sobre CLS: pesos aleatórios, pesos pré-treinados congelados e atualização de todos os pesos. Pesos e otimizadores são reiniciados em cada ponto.



Faixas: média ± 1 desvio-padrão entre sementes; não são intervalos de confiança. O eixo horizontal é o tamanho total do treino e o vertical é a acurácia no teste.

Resultados e interpretação

Acurácia média ± desvio-padrão por tamanho de treino.

Treino	BoW	Do zero	Congelado	Fine-tuning
50	0.562 ± 0.011	0.500 ± 0.000	0.575 ± 0.085	0.590 ± 0.049
100	0.595 ± 0.000	0.500 ± 0.000	0.623 ± 0.067	0.675 ± 0.007
200	0.637 ± 0.011	0.500 ± 0.000	0.625 ± 0.078	0.722 ± 0.011

No maior tamanho (200), a maior acurácia média foi de **DistilBERT fine-tuning** (0.722). Isso descreve este orçamento e estas amostras; não estabelece superioridade geral do método.

BoW + regressão logística: mudança entre 50 e 200 exemplos: +7.5 pontos percentuais. F1 macro no maior tamanho: 0.636.

DistilBERT do zero: mudança entre 50 e 200 exemplos: +0.0 pontos percentuais. F1 macro no maior tamanho: 0.333.

DistilBERT congelado: mudança entre 50 e 200 exemplos: +5.0 pontos percentuais. F1 macro no maior tamanho: 0.591.

DistilBERT fine-tuning: mudança entre 50 e 200 exemplos: +13.2 pontos percentuais. F1 macro no maior tamanho: 0.719.

A diferença fine-tuning menos congelado no maior treino é +9.7 pontos percentuais. Congelar reduz o número de parâmetros ajustados e evita modificar as representações; fine-tuning pode adaptar as representações, mas exige mais otimização. O encoder aleatório precisa aprender essas representações com os poucos rótulos disponíveis.

Limitações e reprodução

Foram usadas 2 épocas, batches de 8 e truncamento em 64 tokens. BoW recebe os textos completos. Essa diferença de contexto, o orçamento fixo de épocas e as taxas de aprendizado distintas limitam a comparação. As configurações são pré-definidas, sem ajuste com o teste. Há apenas 2 sementes; não se deve inferir significância estatística destas faixas. Para estudar curvas mais estáveis, use configs/full.json e, se desejar ajustar hiperparâmetros, separe uma validação dentro do treino oficial.

As curvas não precisam ser monotônicas. Subamostras, inicialização e otimização afetam os resultados; diferenças pequenas exigem mais repetições. O bônus AG News está implementado como opção, mas só pode ser interpretado depois de sua própria execução.

Arquivos de auditoria: metrics.csv contém cada execução, summary.csv contém a agregação e manifest.json registra configurações, índices, hashes dos dados, revisão do modelo e ambiente.

Fontes

Enunciado: Fine-tuning BERT (Tiago F. Tavares)
Dataset IMDb (Stanford NLP)
Documentação oficial DistilBERT / Transformers